

Sistema de Detecção: Fraudes em Financiamento Veicular

- *PS para Cientista de dados*
- *Humberto Távora*

EDA

Análise Exploratória dos Dados

- Análise Inicial
 - Valores Faltantes
 - Distribuição e Correlações
 - Desbalanceamento de
Classes
-

Análise Inicial

- Mais de 47 mil registros!
- 205 atributos.
- Variáveis do Tipo: Float, Int e Texto


	A	B	C	D	E	F	G	H	I	
1	id	documento	mes_ref	alvo	vlr_financiado	VAR1	VAR2	VAR3	VAR4	VAR5
2	4db9c75f6a31c73414	d92fa549809f55f	202307	0.0	17820.6	16.666.667	0.0	0.0	1.0	
3	9b07d4001632189d1	1af133c9872318	202307	0.0	18513.56	16.666.667	0.0	0.0		27.210.886
4	d55b6a81203f5a5aef	9e95be945b56ff	202307	0.0	22943.8	0.0	0.0	0.0		13.605.443
5	f6bb36049c3b42a62c	50502098d83c3	202307	0.0	19177.58	83.333.336	0.0	0.0		20.408.163
6	2755ed6330b4980ea	aad24a7552d24f	202307	0.0	16644.85	0.0	0.0	0.0	0.0	
7	5e7409b3e5519eff37	6cc605428054b	202307	0.0	18775.41	6.666.667	0.0	0.0	1.0	
8	5d810d095c3f16cce8	f36f853fde5d69f	202307	0.0	19302.63			0.0	0.0	
9	e2f8878a9018464d0c	dd30d228afe3c4	202307	0.0	11957.32	0.25	0.0	0.0	0.0	
10	4c1416274ec54a955	c64cb250137d1c	202307	0.0	21369.24	83.333.336	0.0	0.0	0.0	
11	10e4d7889812f7889	88283eb524c3fa	202307	1.0	25380.23	1.0	0.0	0.0	0.0	1
12	93c06a67af6b87aa9f	d527c74f1e9454	202307	0.0	19332.84	83.333.336	0.0	0.0	1.0	
13	79da9938d61a8bb4d	cd30a14fcc651	202307	0.0	13228.01	83.333.336	0.0	0.0		34.013.603
14	6177a45cb50f7d46d	94163bc59388e	202307	0.0	13164.53			0.0		68.027.214
15	4f80dcbf24c10c3ce9f	66ee31e0e14c0f	202307	0.0	21769.76	0.0	0.0	0.0	0.0	6
16	a727613d0a2990f28	435099e019b08f	202307	0.0	19115.02			0.0	1.0	

Valores Faltantes

- Variáveis com >90% Faltantes: 57
- Variáveis com >80% Faltantes: 95
- Variáveis com >50% Faltantes: 139

Não há evidência estatística de que a proporção de dados faltantes difere entre transações fraudulentas e não fraudulentas!


- Diferença de médias: -0.005
- Razão de médias: 0.99x
- Teste t: estatística = 1.415, p-value = 0.1570




Distribuições - Classe Alvo

Como já esperado, um forte desbalanceamento de classes.



95.84 Alvo = 0 (Legítimo)
4.16 Alvo = 1 (Fraudulento)




Distribuições - Outras Classes




Interessante observar que o mês de dezembro onde houveram mais casos de não pagamento da primeira parcela (percentualmente), foi o mês em que houveram menos propostas.



Distribuições - Reincidência



Como esperado, poucas reincidências.



Correlações


As variáveis **VAR3**, **VAR78**, **VAR124** são as com maior correlação positiva (quanto maior, maior a chance da classe alvo indicar 1), enquanto que as **VAR60** e **VAR72** de correlação negativa (quanto menor, maior a chance da classe alvo indicar 1).



Correlações - Subsample


As variáveis **VAR3**, **VAR78**,
VAR124 se mantiveram, mas
também podemos observar a
VAR171 com uma correlação
relevante.

Vlr_financiado também
apresentou um resultado mais
expressivo.



Outliers

O Atributo de valor financiado apresentou uma quantidade expressiva (799 casos) de outliers.



Modelos e Resultados


Análise do impacto financeiro da nossa solução

- Modelos e abordagens utilizadas
- Métricas avaliadas
- Impacto na operação


Modelos

Duas abordagens foram utilizadas:

- **XGBoost isolado**



- **Stacking Ensemble**
(XGBoost, LightGBM, CatBoost, RL e RF)



Modelos - Métricas Gerais

Maior precisão. Mas captura poucas fraudes reais.



Métrica	Baseline (XGBoost)	Modelo Final	Melhoria
Precision	71.23%	59.62%	-17.7%
Recall	13.10%	15.62%	+19.0%
F1-Score	22.13%	24.75%	+11.8x%
Impacto Financeiro	R\$ 1.268.153,70	R\$ 1.477.419,00	+16.5%
Alert Rate	1.00%	1.09%	+0.9%



Maior impacto e equilíbrio entre as métricas.

Métricas Importantes

Threshold	Alert Rate	Precision	Recall	F1	Impacto Líquido	Recomendação
0.9176	1.51%	47.22%	17.13%	25.14%	1.54M	Alto Impacto
0.7799	2.00%	37.70%	18.14%	24.49%	1.55M	 Máximo Impacto
0.5726	2.50%	57.26%	18.89%	23.58%	1.51M	Bom Equilíbrio
0.9845	1.09%	59.62%	15.62%	24.75%	1.47M	 Conservador

O cenário conservador seria o mais recomendado, apresentando um bom equilíbrio entre as métricas, uma precisão maior e o menor impacto na operação do cliente pela baixa taxa de alertas.

Métricas de acompanhamento

- A implementação do modelo mais recomendado gera um **lucro de 1,477,419.0450!**
- Garantindo que a operação do cliente não seja muito impactada com poucos cenários de alerta e pouquíssimos cenários de falsos positivos.

```
lucro_bons_aprovados (TN): 8,649,437.8455  
perda_bons_bloqueados (FP): 46,614.2405  
perda_fraudes_aprovadas (FN): 7,125,404.5600  
ganho_fraudes_bloqueados (TP): 1,602,090.9900  
impacto_liquido: 1,477,419.0450  
precisao: 0.5962  
recall: 0.1562  
alerts: 104
```



Obrigado!